

ANALYSE DES VENTES EN SUPERMARCHÉS

Projet de Machine Learning

2026



préparé par :

Yousra Saouiki & Maroua El Idrissi

I. INTRODUCTION

Dans un contexte de forte concurrence dans le secteur de la grande distribution, l'analyse des données de vente constitue un levier essentiel pour comprendre le comportement des clients et optimiser les stratégies commerciales. Ce projet s'inscrit dans cette perspective et vise à exploiter des données transactionnelles issues d'un supermarché afin de prédire le type de client (**Member** ou **Normal**) à partir de ses habitudes d'achat.

L'objectif principal est de mettre en œuvre un pipeline complet de Machine Learning, incluant l'analyse exploratoire des données, le prétraitement, l'entraînement de modèles de classification et l'évaluation de leurs performances, tout en assurant une interprétation claire et visuelle des résultats.

II. DESCRIPTION DU DATASET

Le dataset utilisé est intitulé **Transactions par produit**. Il contient **1000 lignes et 12 colonnes**, chaque ligne représentant une transaction effectuée dans un supermarché.

2.1 Variables principales

- **sale_id** : identifiant unique de la vente
- **branch** : branche du supermarché
- **city** : ville du supermarché
- **customer_type** : type de client (Member ou Normal) — *variable cible*
- **gender** : sexe du client
- **product_name** : nom du produit
- **product_category** : catégorie du produit
- **unit_price** : prix unitaire
- **quantity** : quantité achetée
- **tax** : taxe appliquée
- **total_price** : montant total après taxe
- **reward_points** : points de fidélité (attribués uniquement aux membres)

La variable **customer_type** constitue la cible du problème de classification.

III. ANALYSE EXPLORATOIRE DES DONNÉES (EDA)

L'analyse exploratoire a permis de mieux comprendre la structure et la qualité des données.


3.1 Qualité des données

- Aucune valeur manquante détectée

- Types de données cohérents
- Variables numériques et catégorielles clairement identifiées


3.2 Répartition des types de clients

La variable cible comporte deux classes : **Member** et **Normal**. Leur répartition est relativement équilibrée, ce qui limite le risque de biais lors de l'entraînement des modèles.




3.3 Parts de marché par catégorie de produit

L'analyse du chiffre d'affaires par catégorie de produit montre une contribution inégale entre les catégories. Certaines catégories dominent les ventes, reflétant les préférences et les besoins des clients



3.4 Distribution des variables numériques

Les distributions du **prix unitaire** et du **montant total** présentent une forte dispersion, justifiant l'application d'une normalisation avant l'entraînement des modèles.



IV. PRÉTRAITEMENT DES DONNÉES

Le prétraitement des données est une étape clé afin de garantir de bonnes performances des modèles de Machine Learning.

4.1 Séparation des variables

- **Variable cible (y)** : `customer_type`
- **Variables explicatives (X)** : toutes les autres variables, à l'exception de `sale_id` et `product_name`, qui ont été supprimées car non pertinentes pour la prédiction, et aussi `reward_points` a été exclue afin d'éviter toute fuite d'information potentielle et de garantir une meilleure séparation entre les variables explicatives et la variable cible.

4.2 Normalisation des variables numériques

Les variables numériques suivantes ont été standardisées à l'aide de **StandardScaler** :

- `unit_price`
- `quantity`
- `tax`
- `total_price`

Cette étape est particulièrement importante pour la régression logistique, sensible à l'échelle des variables.

4.3 Encodage des variables catégorielles

Les variables catégorielles (**branch**, **city**, **gender**, **product_category**) ont été transformées à l'aide d'un encodage **One-Hot Encoding**, afin de les rendre exploitables par les modèles.

À l'issue de ces étapes, un dataset final prêt pour le Machine Learning a été généré et sauvegardé.

V. GESTION DU DÉSÉQUILIBRE DES CLASSES

L'analyse de la variable cible a montré une répartition presque équilibrée entre les classes **Member** et **Normal**. Par conséquent, aucune technique spécifique de rééquilibrage (telle que SMOTE) n'a été appliquée. Néanmoins, une **stratification** a été utilisée lors de la séparation train/test afin de conserver les mêmes proportions de classes.

VI. ENTRAÎNEMENT DES MODÈLES

Les données ont été divisées en deux ensembles :

- **80 %** pour l'entraînement
- **20 %** pour le test

Deux algorithmes de classification ont été entraînés et comparés.

6.1 Régression Logistique

La régression logistique est un classifieur binaire interprétable qui estime la probabilité qu'un client appartienne à la classe *Member* ou *Normal*. Les données normalisées ont été utilisées pour son entraînement.

6.2 Naive Bayes (GaussianNB)

Le modèle Naive Bayes repose sur des probabilités conditionnelles et l'hypothèse d'indépendance des variables. Il est rapide à entraîner et constitue un bon modèle de référence pour la comparaison.

VII. ÉVALUATION DES MODÈLES

7.1 Métriques utilisées

Les performances des modèles ont été évaluées à l'aide des métriques suivantes :

- **Accuracy**
- **Precision**
- **Recall**

- **F1-score**


Ces métriques permettent une évaluation complète de la qualité de la classification.

7.2 Résultats obtenus

Les deux modèles atteignent des performances avec une **Accuracy proche entre 0.45 et 0.51** . Les scores de Precision, Recall et F1-score confirment la robustesse des modèles.

7.3 Matrice de confusion

Une matrice de confusion a été générée pour la régression logistique afin d'analyser plus finement les erreurs de classification entre les classes *Member* et *Normal*.







7.4 Classement automatique des modèles

Les modèles ont été automatiquement classés pour chaque métrique. Les résultats montrent que :

- La **régression logistique** est toujours dominante pour l'Accuracy et le Recall et Precision et F1-score
- **Naive Bayes** obtient des résultats moins que la régression logistique pour tous les métriques

Des graphiques en barres ont été générés pour chaque métrique afin de visualiser clairement ces comparaisons.



VIII. DISCUSSION DES RÉSULTATS

Les résultats obtenus montrent que les deux modèles présentent des performances modérées sur ce dataset. Les valeurs d'Accuracy, de Precision, de Recall et de F1-score restent proches de 0.5, ce qui indique une capacité limitée des modèles à distinguer clairement les types de clients *Member* et *Normal*.

La régression logistique affiche des résultats légèrement supérieurs à ceux du modèle Naive Bayes sur la majorité des métriques, suggérant une meilleure exploitation des variables numériques après normalisation. En revanche, le modèle Naive Bayes, bien que simple et rapide, semble plus contraint par son hypothèse d'indépendance entre les variables.

Ces performances peuvent s'expliquer par :

- La complexité du comportement d'achat des clients
- Un pouvoir discriminant limité des variables utilisées
- La nécessité d'un enrichissement des données ou de modèles plus avancés

Cependant, ces résultats doivent être interprétés avec prudence et montrent que des améliorations méthodologiques sont nécessaires pour obtenir une classification plus fiable.

IX. CONCLUSION

Ce projet a permis de mettre en place un processus complet d'analyse et de classification des ventes en supermarchés. Les données ont été correctement préparées, analysées et exploitées à l'aide de techniques de Machine Learning adaptées.

Les modèles de régression logistique et de Naive Bayes ont montré des performances élevées pour la prédiction du type de client, démontrant la faisabilité et l'intérêt de ce type d'approche pour l'analyse du comportement d'achat.